

DỰ ĐOÁN GIÁ TRỊ CẢM BIẾN CHẤT LƯỢNG KHÔNG KHÍ SỬ DỤNG MẠNG NƠ RON TÍCH CHẬP MỘT CHIỀU VÀ MẠNG BỘ NHỚ DÀI NGẮN HẠN

Nguyễn Việt Hưng*, Vũ Hoài Nam*, Vũ Đức Anh*, Trần Quang Hiệp*, Lê Thành Long*

*Học viện Công nghệ Bưu chính Viễn thông

Tóm tắt: Giám sát chất lượng không khí là chủ đề nghiên cứu thách thức nhưng cũng đầy tính thực tiễn của lĩnh vực học máy và phân tích dữ liệu. Chất lượng không khí ảnh hưởng trực tiếp đến sức khỏe và đời sống của con người trong thời gian dài. Do đó, giá trị đo lường của các cảm biến đánh giá chất lượng không khí luôn nhận được nhiều sự quan tâm của người dân cũng như các cơ quan chính quyền. Hiện nay, các trạm quan trắc chất lượng không khí tại mặt đất được thiết lập phổ biến để đưa ra các giá trị chất lượng không khí tại các khu vực giám sát. Thiết bị bay không người lái (UAV - Unmanned Aerial Vehicles) được cũng dần được đưa vào sử dụng phổ biến cho các ứng dụng giám sát sử dụng camera. Tuy nhiên, sử dụng UAV trong giám sát và dự đoán chất lượng không khí vẫn còn là lĩnh vực mới đang nhận được nhiều sự quan tâm của các nhóm nghiên cứu lớn trên thế giới. Để giải quyết bài toán dự đoán chất lượng không khí dựa vào những giá trị cảm biến đo được từ thiết bị bay không người lái, chúng tôi đề xuất một mô hình kết hợp mạng nơ ron tích chập một chiều và mạng bộ nhớ dài ngắn hạn (CNN-LSTM). Với những kết quả đạt được từ thử nghiệm với bộ dữ liệu mà chúng tôi thu thập được, mô hình đề xuất cho thấy tính hiệu quả và thực tiễn cao, có khả năng đưa vào triển khai trong các ứng dụng thực tế, thêm một nguồn giám sát chất lượng hữu ích kết hợp với các trạm đo mặt đất hiện tại đang được triển khai

Từ khóa: mạng nơ ron tích chập, giám sát chất lượng không khí, UAV, mạng bộ nhớ dài-ngắn hạn.

1. MỞ ĐẦU

Ngày nay, các vấn đề môi trường và đặc biệt là về chất lượng không khí đang được quan tâm hơn bao giờ hết. Ô nhiễm không khí là thách thức lớn đối với các thành phố và khu công nghiệp, tác động nghiêm trọng đến các vấn đề liên quan đến đường hô hấp của con người. Theo Tổ chức Y tế Thế giới, 7 triệu người đang gặp rủi ro về sức khỏe do ô nhiễm không khí [1]. Đây là yếu tố gây nguy cơ hàng đầu đối với phần lớn các vấn đề sức khỏe như hen suyễn, nhiễm trùng da, các vấn đề về tim, cổ họng và mắt, viêm phế quản, ung thư phổi và các bệnh về hệ hô hấp.

Bên cạnh những vấn đề sức khỏe liên quan đến ô nhiễm không khí, nó còn là mối đe dọa nghiêm trọng đối với hành tinh của chúng ta. Ô nhiễm phát thải từ các nguồn như xe cộ và công nghiệp là nguyên nhân cơ bản của hiệu ứng nhà kính, khí thải CO₂ là một trong những nguyên nhân quan trọng nhất gây ra hiện tượng nhà kính [2]. Biến đổi khí hậu đã được thảo luận rộng rãi tại các diễn đàn toàn cầu và vẫn là một vấn đề nhức nhối đối với thế giới kể từ hai thập kỷ qua do hậu quả của sự gia tăng khối bụi và thiệt hại tầng ôzôn. Đánh giá chất lượng không khí là một cách quan trọng để giám sát và kiểm soát ô nhiễm không khí. Một số chất ô nhiễm không khí, được gọi là chất ô nhiễm không khí tiêu chuẩn, các chất ô nhiễm này có thể gây tổn hại đến sức khỏe, gây hại cho môi trường và tài sản. Các chất ô nhiễm hiện nay là: Carbon Monoxide (CO), Chì (Pb), Nitrogen Dioxide (NO₂), Ozone (O₃), Particulate matter (PM), Sulfur Dioxide (SO₂).

Các điều kiện khí tượng, bao gồm khí tượng khu vực và khí tượng tổng quát có vai trò rất quan trọng trong việc xác định nồng độ chất ô nhiễm không khí [3 – 8]. Ví dụ, nhiệt độ môi trường thấp kèm theo bức xạ mặt trời làm chậm phản ứng quang hóa và dẫn đến ít chất ô nhiễm không khí thứ cấp hơn, chẳng hạn như O₃ [9]. Tốc độ gió tăng có thể làm tăng hoặc giảm nồng độ chất ô nhiễm trong không khí. Ví dụ, khi tốc độ gió thấp, các chất ô nhiễm liên quan đến giao thông đo được có nồng độ cao nhất [10, 11]. Tuy nhiên, tốc độ gió mạnh có thể tạo thành bão bụi bằng cách thổi tung các hạt trên mặt đất [12]. Độ ẩm cao thường liên quan đến nồng độ cao của một số chất ô nhiễm không khí (như PM, CO và SO₂) nhưng với các chất ô nhiễm không khí khác (như NO₂ và O₃) lại có nồng độ thấp, do có nhiều cơ chế hình thành và loại bỏ khác nhau [11]. Ngoài ra, độ ẩm cao có thể là một chỉ báo của các hiện tượng lượng mưa, dẫn đến lắng đọng ẩm ướt mạnh làm cho nồng độ chất ô nhiễm không khí giảm [13]. Đám mây có thể tán xạ và hấp thụ bức xạ mặt trời, điều này có ý nghĩa đối với việc hình thành một số chất ô nhiễm không khí (ví dụ, O₃) [9, 14]. Do đó, các biến số khí tượng là một tham số quan trọng để dự đoán nồng độ chất ô nhiễm trong không khí.

Trước sự cấp thiết của vấn đề môi trường, đặc biệt là giám sát chất lượng không khí, việc ứng dụng IOT (Internet of thing) trở nên phổ biến rộng rãi. Ý tưởng điển hình để giám sát chất lượng không khí là sử dụng các cảm biến có chức năng đo nồng độ các thành phần không khí được đặt cố định tại các vị trí chiến lược nhất định. Sau đó


Tác giả liên hệ: Nguyễn Việt Hưng,

Email: nvhung_vt1@gmail.com

Đến tòa soạn: 10/2020, chỉnh sửa: 11/2020, chấp nhận đăng: 12/2020.

các thông tin về chất lượng không khí được gửi về trung tâm. Tuy nhiên, việc này lại rất tốn kém và khó triển khai tại một số địa điểm. Mặt khác, trong trường hợp số lượng cảm biến là có hạn, việc giám sát chất lượng không khí chỉ được thực hiện tại các vị trí cố định, chúng ta không thể có thông tin chất lượng không khí chi tiết trên một vùng diện rộng và có một cái nhìn tổng quan về chất lượng không khí tại các địa điểm.

Bên cạnh việc giám sát, dự đoán chất lượng không khí cũng là yêu cầu quan trọng cho các hệ thống giám sát môi trường. Có nhiều phương pháp để dự đoán chất lượng không khí, trong đó các thuật toán Machine learning là một sự lựa chọn phổ biến. Ví dụ, trong một nghiên cứu gần đây [15] trình bày phương pháp sử dụng trí tuệ nhân tạo dựa trên mô hình mạng nơ-ron Deep Multi-Output LSTM (DM-LSTM) để dự đoán chất lượng không khí ở thành phố Đài Bắc, Đài Loan. Nghiên cứu này rất hứa hẹn nhưng dữ liệu sử dụng trong nghiên cứu được tạo ra bởi năm trạm quan trắc chất lượng không khí cố định trong thành phố. Do đó, những bộ dữ liệu này không phản ánh nồng độ ô nhiễm ở mức chi tiết tại từng địa điểm. Tương tự, các phương pháp dựa trên dữ liệu khác đã được sử dụng để dự đoán chất lượng không khí như DEA (data envelopment analysis) trong [16]. Tuy nhiên, thông tin đang được sử dụng đến từ các nguồn dữ liệu cố định, không phải các đơn vị cảm biến di động có thể được mang theo hàng ngày.



Hình 1. Hệ thống giám sát và dự đoán chất lượng không khí

Để giải quyết những vấn đề còn tồn đọng được nêu trên, trong bài báo này, chúng tôi tập trung nghiên cứu và đề xuất phương pháp sử dụng mô hình CNN - LSTM cho bài toán dự đoán chất lượng không khí. Một điểm khác biệt trong nghiên cứu này với những công trình nghiên cứu trước đó là chúng tôi sử dụng thiết bị không người lái có gắn cảm biến để thực hiện đo chất lượng không khí tại một số điểm, sau đó sử dụng mô hình học sâu để dự đoán chất lượng không khí tại các điểm còn lại và những biến đổi về chất lượng không khí theo thời gian. Chi tiết trong đóng góp nghiên cứu của chúng tôi gồm 3 phần chính:

- Đề xuất mô hình CNN - LSTM trích xuất đặc trưng từ dữ liệu thu thập được từ cảm biến trên thiết bị bay không người lái.
- Chúng tôi xây dựng bộ cơ sở dữ liệu (dataset) về chất lượng không khí tại các khu vực riêng biệt. Đồng thời, chúng tôi cũng đánh giá phương pháp đề xuất trên dataset đã thu thập và phân tích các kết quả thu thập được.
- Xây dựng một hệ thống thử nghiệm (prototype) để thực hiện phương pháp được đề xuất.

II. NGHIÊN CỨU LIÊN QUAN

Trong các nghiên cứu trước đây về giám sát và dự đoán chất lượng không khí chia làm hai loại chính: mô hình tiên định (deterministic) và mô hình thống kê. Mô hình tiên định là các mô hình sử dụng lý thuyết về khí tượng, vật lý và hóa học để mô phỏng quá trình chuyển dịch, khuếch tán hoặc loại bỏ (elimination) các chất gây ô nhiễm. Các mô hình deterministic có thể kể đến như CMAQ (Community Multiscale Air Quality) [17] và WRF-Chem (Weather Research and Forecasting model coupled with Chemistry) [18]. Các mô hình dựa trên phân tích lý thuyết này được sử dụng rộng rãi trong cộng đồng nghiên cứu môi trường và khí quyển [19, 20]. Tuy nhiên, do các yếu tố như sai số của dữ liệu, điều kiện địa lý phức tạp và nền tảng lý thuyết không chặt chẽ, các phương pháp này thường có độ chính xác hạn chế [21,22]. Mặt khác, những phương pháp trên không giải quyết được vấn đề thời gian thực trong dự đoán do chúng yêu cầu những tính toán cụ thể với tất cả các điểm phi tuyến tính trong bầu khí quyển phức tạp, dẫn đến thời gian tính toán kéo dài.

A. Sử dụng machine learning

Khắc phục những vấn đề của mô hình deterministic, nhiều nghiên cứu đã ứng dụng thuật toán Machine Learning cho dự đoán chất lượng không khí. Các mô hình Machine Learning không yêu cầu quá trình xử lý vật lý và hóa học phức tạp như mô hình deterministic mà sử dụng dữ liệu không khí được thu thập trước đó để dự đoán chất lượng không khí trong khoảng thời gian tiếp theo. Ngoài ra, cách tiếp cận bằng Machine Learning giúp giải quyết vấn đề phi tuyến tính và cải thiện hiệu suất và độ chính xác của mô hình. Mô hình hồi quy tuyến tính (Linear model regression) là một mô hình cơ bản trong Machine learning. Một số nhà nghiên cứu đã áp dụng phương pháp này cho bài toán dự đoán chất lượng không khí. Ví dụ, Rajput và cộng sự sử dụng mô hình multiple linear regression để dự đoán chất lượng không khí tại Ấn Độ [23]. Tuy nhiên, trên thực tế, các chất ô nhiễm không khí có quan hệ phi tuyến với các yếu tố ảnh hưởng của chúng. Singh và cộng sự [24] đã so sánh các phương pháp tuyến tính và phương pháp phi tuyến và nhận thấy rằng phương pháp phi tuyến có thể thu thập được tính phi tuyến phức tạp trong dữ liệu chất lượng không khí. Do đó, các mô hình phi tuyến, chẳng hạn như mạng nơ-ron nhân tạo (ANN) [25] phù hợp hơn các mô hình tuyến tính. Azid và cộng sự [26] kết hợp Principal Component Analysis (PCA) và ANN để dự đoán chất lượng không khí ở Malaysia. De Vito và cộng sự [27] cải tiến ANN với cách tiếp cận động. Kang [28] đã sử dụng dữ liệu của Lanzhou và ANN được tối ưu hóa bằng thuật toán di truyền (genetic simulated annealing) để dự đoán chất lượng không khí. Paoli và cộng sự [29] đã sử dụng ANN để dự đoán O₃ ở Corsica. Mahajan và cộng sự [30] đã sử dụng phương pháp clustering dựa trên khoảng cách địa lý để cải thiện hiệu suất của ANN ở 4 thành phố của Đài Loan. Một phương pháp phi tuyến khác là Support vector machine (SVM) [31] cũng được các nhà nghiên cứu ưa chuộng vì nó có khả năng tổng quát hóa tốt hơn ANN. Sanchez và cộng sự [32] nhận thấy rằng SVM thường có hiệu suất tốt hơn ANN bằng cách so sánh SVM với các nhân (kernel) khác nhau và ANN. Nieto và cộng sự [33] đã sử dụng phương pháp dựa trên PSO-SVM để dự đoán chất lượng không khí ở phía bắc Tây Ban Nha. Gu và cộng sự [34] trích xuất thông tin tuần tự (sequential information) của dự đoán bằng cách áp dụng phương pháp hồi quy (recurrent) cho SVM.

B. Sử dụng deep learning

Mặc dù đạt hiệu suất cải thiện so với mô hình tiền định, nhưng các mô hình Machine Learning thường phải sử dụng các phương pháp phức tạp để tiền xử lý dữ liệu, trích xuất đặc trưng thủ công. Dữ liệu không gian-thời gian trong giám sát chất lượng không khí thường được đặc trưng bởi các mối tương quan không gian, thời gian. Nắm bắt được những phụ thuộc này là nhiệm vụ rất quan trọng. Học sâu (Deep learning) là một phương pháp đầy hứa hẹn để giải quyết vấn đề này, lý do bởi khả năng tự động trích xuất đặc trưng và mối quan hệ phức tạp của các yếu tố đầu vào. Ví dụ, sử dụng stacked autoencoder (SAE) để trích xuất thông tin từ 12 trạm và sau đó nạp thông tin đã trích xuất vào một hồi quy tuyến tính (LR) để dự đoán chất lượng không khí tại 12 trạm đồng thời [35].

Tuy nhiên, dữ liệu chất lượng không khí là tuần tự, do đó, các mô hình xử lý tốt dữ liệu tuần tự như Mạng nơ ron hồi quy (Recurrent neural network - RNN) mạnh hơn SAE, ANN và SVM trong dự đoán chất lượng không khí. Ong và cộng sự [36] cũng sử dụng SAE nhưng thay thế LR bằng RNN để cung cấp thời gian dự đoán 12 giờ. Tuy nhiên, RNN có hai nhược điểm kinh điển: gradient bùng nổ (exploding gradient) và gradient tiêu biến (vanishing gradient).

Do đó, một số nghiên cứu đã sử dụng Long Short-Term Memory (LSTM) để dự đoán chất lượng không khí. Ví dụ, sử dụng LSTM để dự đoán chất lượng không khí tương ứng trong 12 giờ và 24 giờ tiếp theo [37, 38]. Zhao và cộng sự [39] đã sử dụng thông tin của các trạm lân cận và LSTM để xây dựng mô hình. Wang và cộng sự [40] cũng sử dụng LSTM nhưng họ đã áp dụng luật nhân quả Granger (Granger causality) để chọn các trạm đo có độ liên quan cao. Zhou và cộng sự [41] đã thiết lập một mô hình dựa trên LSTM để dự đoán chất lượng không khí của một số trạm. Một số nghiên cứu nhận thấy rằng RNN có thể đạt được kết quả tốt hơn ANN và SVM [42, 43]. Gated Recurrent Unit (GRU) là một phiên bản đơn giản hóa của LSTM và một số nhà nghiên cứu đã áp dụng phương pháp này để dự đoán chất lượng không khí. Athira và cộng sự [44] so sánh RNN, LSTM và GRU để dự đoán chất lượng không khí và các thí nghiệm của họ cho thấy GRU có hiệu suất tốt nhất. Wang và cộng sự [45] đã thêm một kết nối dư (residual connection) vào GRU và LSTM, họ nhận thấy rằng GRU có hiệu suất tốt hơn LSTM. Thay vì tiền xử lý dữ liệu bằng RNN, dữ liệu được xử lý trước bằng hàm tích chập trước khi đưa chúng vào dự đoán, thí nghiệm của họ cho thấy GRU có kết quả tốt hơn LSTM, ANN, SVM, random forest và MLR. Một số nghiên cứu [47, 48, 49] sử dụng mạng nơ ron tích chập (Convolutional neural network - CNN) [50] để tiền xử lý dữ liệu thô và sau đó đưa chúng vào LSTM. Soh và cộng sự [51] đã sử dụng CNN để trích xuất thông tin địa hình, ví dụ, một ngọn núi giữa các trạm và sử dụng LSTM và ANN để trích xuất thông tin từ trạm mục tiêu và các trạm liên quan cao được chọn theo phương pháp phân cụm. Cuối cùng, họ đã tổng hợp tất cả thông tin để đưa ra dự đoán cuối cùng. Pan và cộng sự [52] đã thiết lập một mô hình bao gồm các mô đun không gian (spatial), thời gian (temporal) và trung gian (deduction). Mô đun trung gian trích các tham số của các mô đun không gian và thời gian. Mô đun có thể là các mô hình CNN, LSTM hoặc ANN, sử dụng để đưa ra dự đoán cuối cùng.

Trong nghiên cứu này, chúng tôi đề xuất phương pháp thu thập dữ liệu nồng độ ô nhiễm không khí trên thiết bị

bay không người lái, sử dụng mô hình CNN - LSTM cho dự đoán chất lượng không khí giúp trích xuất các đặc trưng về không gian và thời gian, cải thiện hiệu suất so với các phương pháp trước đây.

III. PHƯƠNG PHÁP ĐỀ XUẤT

Phương pháp đề xuất sử dụng mô hình đa tầng CNN + LSTM. CNN có đặc tính là chú ý đến những đặc trưng rõ ràng nhất trong luồng dữ liệu nên dễ dàng nhận thấy tác động của đầu vào đối với đầu ra. Với đầu vào ở dạng chuỗi thời gian, chúng tôi chọn LSTM (Long-short term memory) để giải quyết vấn đề này. LSTM là một mô hình được xây dựng để giải quyết vấn đề exploding gradient và vanishing gradient trong các bước trước đó trong chuỗi thời gian. Với thuật toán này, chúng tôi sử dụng các giá trị ở t bước thời gian (timesteps) trước đó để dự đoán bước thời gian $t + 1$. Trong mỗi bước thời gian, chúng tôi quyết định sử dụng các tham số của K điểm gần nhất làm đặc trưng của bước thời gian này. K và t tối ưu được chọn dựa trên kết quả thực nghiệm.

Bảng 1. Thông số mô hình CNN-LSTM

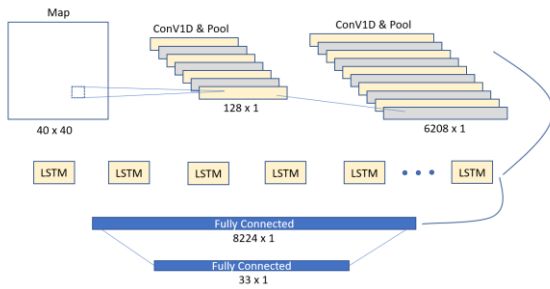
Các lớp của mô hình	Kích thước lớp	Kích thước đầu ra
Input	-	167 x 1
Conv1D	128	167 x 32
BatchNormalization	128	167 x 32
Conv1D	6208	167 x 64
BatchNormalization	256	167 x 64
LSTM	328704	256
Dense	8224	32
Dense	33	1

Dữ liệu thô ban đầu sẽ có dạng $N*N*T$ (với $N*N$ là số điểm dùng lấy mẫu, trong trường hợp này $N = 40$). Dữ liệu này sẽ được xử lý trước khi cho vào mô hình huấn luyện. Sau khi tiền xử lý, dữ liệu đầu vào sẽ có dạng $N*N*K*K*T$ (K là kích thước hình vuông có trung tâm ứng với vị trí điểm cần dự đoán). Đầu ra của dữ liệu cảm biến sẽ có dạng một mảng đặc trưng F là kết quả đã được dự đoán cho thời gian $T+1$ mà chúng ta đã đặt ra trước đó. Các bước chính như sau:

- Dữ liệu đầu vào: nhập dữ liệu cần thiết cho việc huấn luyện mô hình CNN-LSTM.
- Chuyển đổi dữ liệu bằng cách sử dụng k điểm gần nhất làm đặc trưng cho điểm cần huấn luyện.
- Khởi tạo mạng: khởi tạo trọng số và độ lệch của từng lớp của mô hình CNN-LSTM.
- Tính toán tại lớp CNN: dữ liệu đầu vào liên tiếp được chuyển qua lớp Convolution và lớp Batch Normalization trong lớp CNN, việc trích xuất đặc trưng của dữ liệu đầu vào được thực hiện và thu được giá trị đầu ra.
- Tính toán tại lớp LSTM: dữ liệu đầu ra của lớp CNN được tính toán thông qua lớp LSTM và thu được giá trị đầu ra.
- Tính toán lớp đầu ra: giá trị đầu ra của lớp LSTM được đưa vào lớp Dense (Fully connected) để lấy giá trị đầu ra.

- Tính toán lỗi: ta đem giá trị đầu ra do lớp đầu ra tính toán được so sánh với giá trị thực của nhóm dữ liệu này và thu được sai số tương ứng. (Sử dụng MPAE).

- Lưu mô hình: lưu mô hình vừa đào tạo.



Hình 2. Kiến trúc mô hình CNN-LSTM

A. CNN

CNN là một mô hình mạng được đề xuất bởi Lecun et al. vào năm 1998. CNN là một loại mạng nơ-ron truyền thẳng, có hiệu suất tốt trong xử lý hình ảnh và xử lý ngôn ngữ tự nhiên. Nó có thể được áp dụng hiệu quả để dự báo chuỗi thời gian. CNN chủ yếu bao gồm hai phần: lớp chập và lớp gộp. Mô hình CNN thường được thiết kế để hoạt động trên dữ liệu hai chiều như hình ảnh và videos. Vì lý do này, mô hình CNN thường được đề cập đến là mô hình CNN hai chiều (2D-CNN) hay Conv2D. Gần đây, để giải quyết các vấn đề liên quan đến dữ liệu một chiều dạng time series, mô hình CNN 1 chiều hay Conv1D được phát triển. Mô hình CNN một chiều này tỏ ra hiệu quả khi làm việc với đầu vào là dữ liệu dạng time series vì những lý do sau:

- So với những phép tính toán ma trận được thực hiện sử dụng trong mô hình 2D-CNN, mô hình 1D-CNN có thể áp dụng những phép tính toán trên mảng đơn giản hơn do đó giảm đáng kể độ phức tạp tính toán.

- Hầu hết các kiến trúc 1D-CNN khá nông. Những mô hình này có số lượng những lớp ẩn và số lượng nơ ron ít hơn. Do đó, mô hình 1D-CNN tỏ ra hiệu quả khi cho phép quá trình huấn luyện diễn ra đơn giản hơn và dự đoán hiệu quả hơn.

- Kiến trúc 1D-CNN có thể mô hình hóa được những đặc tính về thời gian của dữ liệu time series, qua đó học và biểu diễn hiệu quả những đặc trưng từ dữ liệu cảm biến. Do đó, mô hình 1D-CNN phù hợp với dữ liệu cảm biến được sử dụng trong bài toán phân tích chất lượng không khí này.

Trong mô hình được đề xuất của chúng tôi, chúng tôi đã sử dụng mô đun Conv1D để trích xuất các đặc trưng không gian của dữ liệu và sử dụng nó làm đầu vào của mô hình học sâu LSTM.

B. LSTM

Một mô hình LSTM gồm 1 tế bào (cell), 1 cổng vào, 1 cổng quên và 1 cổng ra. Cell lưu giữ giá trị trong khoảng thời gian và các cổng điều khiển luồng thông tin ra vào tế bào đó. Công thức dẫn xuất cụ thể của LSTM được minh họa trong Công thức (1) - (7). Trong phương pháp đề xuất của chúng tôi, lớp LSTM được xếp chồng lên sau CNN để tìm hiểu mối quan hệ giữa số ngày và chất lượng không khí của các điểm xung quanh.

Đầu ra của LSTM là cell state c_t và hidden state h_t . Đầu vào của nó là cell state của timestep trước đó c_{t-1} , hidden state của timestep trước đó h_{t-1} và đầu vào của it trạng thái (x_t).

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (1)$$

$$f_t = \text{sigmoid}(U_f * x_t + W_f * h_{t-1} + b_f) \quad (2)$$

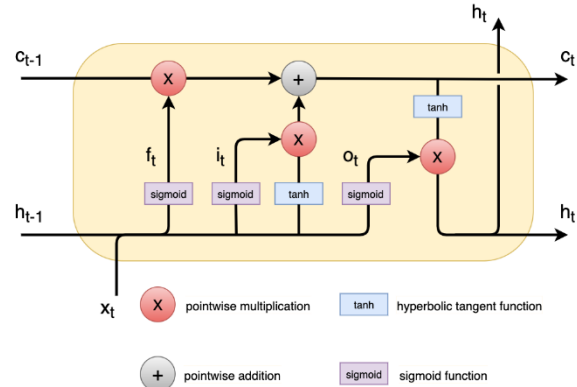
$$i_t = \text{sigmoid}(U_i * x_t + W_i * h_{t-1} + b_i) \quad (3)$$

$$o_t = \text{sigmoid}(U_o * x_t + W_o * h_{t-1} + b_o) \quad (4)$$

$$c_t = f_t * c_{t-1} + i_t * \tanh(U_c * x_t + W_c * h_{t-1} + b_c) \quad (5)$$

$$h_t = o_t * \tanh(c_t) \quad (6)$$

Trong đó U_f, U_c, U_i, U_o là các trọng số đầu vào, W_f, W_c, W_i, W_o là các trọng số hồi quy và b_f, b_c, b_i, b_o là các bias.




Hình 3. Kiến trúc một cell trong mô hình LSTM

IV. KẾT QUẢ THỰC NGHIỆM

Trong phần này, chúng tôi tập trung đánh giá phương pháp CNN - LSTM trên tập dữ liệu đã được thu thập bằng thiết bị bay không người lái. Chúng tôi trình bày phương pháp thu thập dữ liệu tại mục A. Tiếp đó, đưa ra kết quả và phân tích, đánh giá tại mục B và C tương ứng.

A. Thu thập dữ liệu



Hình 4. Thiết bị thu thập dữ liệu

Chúng tôi đề xuất sử dụng thiết bị bay không người lái để thực hiện thu dữ liệu chất lượng không khí. Những lợi ích của thiết bị không người lái trong việc thu dữ liệu chất lượng không khí như: Giá thành thấp; tính linh hoạt có thể áp dụng cho nhiều ứng dụng nghiên cứu khí quyển; linh hoạt, tiết kiệm thời gian và dễ dàng triển khai. Thiết bị UAV chúng tôi sử dụng được đưa ra trong hình 4 bao gồm các chức năng cơ bản đó là: Thu nhận tín hiệu cảm biến, camera; điều khiển động cơ máy bay không người lái; lưu trữ dữ liệu thu thập được; mô đun truyền thông về mặt đất và tích hợp GPS. Mỗi phiên bản phân cứng thu thập dữ liệu sẽ bao gồm 3 bộ phận chính là:

- Bộ phận thu nhận tín hiệu (bao gồm cảm biến và camera nhiệt): Là bộ phận được tích hợp các loại cảm biến khác nhau và camera nhiệt trên một hệ thống các mạch phần cứng cho phép thu nhận dữ liệu của các loại dữ liệu cảm biến và hình ảnh từ camera nhiệt.

- Bộ phận xử lý chính: hay còn gọi là bộ phận khối máy xử lý chính (Main Embedded Computer - MEC). MEC có chức năng chính là thu nhận thông tin từ bộ phận cảm biến, tiền xử lý dữ liệu cảm biến sau đó lưu trữ vào bộ nhớ của thiết bị bay.

- Bộ phận giao diện phối ghép: Chứa các mô đun giao tiếp từ thiết bị bay không người lái vào các mô đun lưu trữ. Các mô đun này được thiết kế chế tạo theo chuẩn về giao tiếp truyền thông dựa trên các giao thức thông dụng để dễ dàng kết nối từ máy chính MEC về phần cứng lưu trữ. Các mô đun của bộ phận phối ghép có hai chức năng chính: Một là tiếp nhận tín hiệu cảm biến từ bộ phận thu nhận tín hiệu cảm biến và hình ảnh để đưa tới các thành phần khác của MEC cho việc xử lý tín hiệu tiếp theo; hai là, lưu trữ các dữ liệu thu được vào bộ nhớ của thiết bị bay.

Chúng tôi đã lựa chọn khu vực xung quanh Học viện Công nghệ Bưu chính Viễn thông để thu dữ liệu. Dữ liệu được thu qua 1 thiết bị UAV trong khu vực của Học viện có kích thước 900x900m được chia thành lưới với mỗi ô có kích thước 22,5x22,5m. Chúng tôi lựa chọn khu vực trên với kích thước 900x900m nhằm mô phỏng lại diện tích của một khu công nghiệp nhỏ. Khu vực trên bao gồm nhiều tuyến đường giao thông chính, bệnh viện, các công ty với chỉ số chất lượng không khí thường xuyên ở ngưỡng không lành mạnh, các chỉ số cho các loại khí ở mức cao và thay đổi theo từng giờ. Với khu vực đó, chúng tôi thực hiện lộ trình bay cho UAV như sau: UAV sẽ bay quanh khu vực mỗi tiếng một lần, thu dữ liệu tại các điểm trên lưới đó. Với mỗi điểm trên lưới, dữ liệu sẽ bao gồm các thuộc tính: Chỉ số chất lượng không khí (AQI), bụi mịn pm2.5, SO₂, NO₂, CO, kinh độ, vĩ độ của điểm dữ liệu và thời gian thu dữ liệu (năm-tháng-ngày, giờ). Chúng tôi chọn thu dữ liệu trong vòng 1 tuần với mỗi lần đo cách nhau một giờ. Dữ liệu được đo sẽ bao gồm nhiều khung giờ trong ngày, thể hiện được sự khác biệt giữa các khoảng thời gian (giờ cao điểm, khung giờ làm việc, giờ tan làm, giờ nghỉ, ngày nghỉ) đối với chất lượng của không khí trong vòng một tuần. Các mốc thời gian được đo thể hiện sự biến thiên về mặt thời gian ảnh hưởng tới chất lượng không khí từng thời điểm. Cụ thể với các ngày trong tuần vào các giờ cao điểm, chất lượng không khí sẽ giữ ở mức không lành mạnh và vào những thời điểm khác, chất lượng không khí có thể tăng lên ở mức trung bình hoặc không lành mạnh cho các nhóm nhạy cảm. Mô tả chi tiết về từng chỉ số được đưa ra trong bảng dưới đây:

Bảng II. Mô tả dữ liệu

Loại dữ liệu	Chú thích
AQI	Thước đo chất lượng không khí tại 1 thời điểm.
PM2.5	Nồng độ bụi pm2.5(μg/m3).
SO ₂	Nồng độ khí SO ₂ (g/m3).
NO ₂	Nồng độ khí NO ₂ (g/m3).
CO	Nồng độ khí CO (g/m3).

Longitude	Kinh độ tại điểm đo.
Latitude	Vĩ độ tại điểm đo.

B. Chỉ số đánh giá

Chúng tôi sử dụng phần trăm sai số tuyệt đối trung bình (MAPE) làm tiêu chí đánh giá cho bài toán này. MAPE là thước đo độ chính xác dự đoán của một phương pháp dự báo trong thống kê. Công thức của MAPE như sau:

$$M = \frac{100}{n} \sum_{t=1}^n \left| \frac{A_t - F_t}{A_t} \right|$$

Trong đó F_t là giá trị dự đoán và A_t là giá trị thực. Giá trị của MAPE càng nhỏ cho thấy kết quả dự báo càng gần với thực tế.

C. Kết quả

So sánh với các phương pháp khác.

Với thực nghiệm này, chúng tôi đã so sánh phương pháp đề xuất CNN-LSTM với các phương pháp trước đó bao gồm: Linear Regression, KNN sử dụng Gridsearch, LSTM trên cùng tập dữ liệu. Chúng tôi so sánh các phương pháp này với các thông số khác nhau như số lượng ngày lấy mẫu và phạm vi lấy mẫu k (áp dụng cho CNN-LSTM).

Bảng III. Kết quả sử dụng dữ liệu 1 ngày trước

Method		AQI	PM25	SO ₂	NO ₂	CO
CNN - LSTM	K=1	15%	5%	4%	8%	11%
	K=3	16%	17%	18%	16%	14%
	K=5	17%	19%	17%	18%	14%
Linear Regression		8%	9%	5%	28%	7%
KNN		17%	24%	18%	29%	45%
LSTM		9%	8%	5%	8%	8%

Bảng IV. Kết quả sử dụng dữ liệu 3 ngày trước

Method		AQI	PM25	SO ₂	NO ₂	CO
CNN - LSTM	K=1	8%	4%	6%	11%	11%
	K=3	11%	19%	10%	25%	12%
	K=5	14%	21%	13%	20%	14%
Linear Regression		9%	9%	8%	20%	9%
KNN		12%	24%	27%	19%	47%
LSTM		13%	23%	17%	18%	9%

Bảng V. Kết quả sử dụng dữ liệu 7 ngày trước

Method		AQI	PM25	SO ₂	NO ₂	CO
CNN - LSTM	K=1	7%	5%	4%	6%	7%
	K=3	9%	14%	11%	15%	9%
	K=5	10%	16%	14%	20%	11%
Linear Regression		33%	54%	42%	59%	10%
KNN		38%	14%	57%	59%	50%
LSTM		10%	12%	14%	21%	18%

Tổng quan ta có nhận xét rằng độ chính xác của CNN-LSTM đạt được kết quả vượt trội so với các phương pháp trước đó (KNN, Linear Regression). Thể hiện ở giá trị MAPE tốt nhất lần lượt với các khí AQI, PM25, SO₂, CO₂, CO là 7%, 4%, 4%, 6%, 7%. Với các phương pháp trước đó, độ chính xác giảm dần khi tăng số ngày lấy

mẫu. Tuy nhiên với phương pháp CNN-LSTM kết quả có xu hướng tốt khi tăng số ngày lấy mẫu và giảm độ lớn vùng lân cận dùng để lấy mẫu cho mỗi điểm tại đa số các loại khí (AQI, SO₂, CO₂, CO). Xu hướng giảm độ chính xác của phương pháp khi tăng dần độ lớn vùng lấy mẫu có thể giải thích được là do sự xuất hiện nhiều của các vùng xung quanh ảnh hưởng đến việc dự đoán chất lượng không khí tại vùng cần dự đoán. Trong khi đó xu hướng tăng dần độ chính xác của phương pháp khi tăng số ngày làm dữ liệu đầu vào có thể giải thích là do việc tăng số ngày sẽ giúp mô hình có thêm nhiều thông tin hơn để dự đoán. Ngoài ra tính chu kỳ của dữ liệu cũng được thể hiện tốt hơn, giúp mô hình học được các thuộc tính có ý nghĩa hơn. Khi so sánh với phương pháp phổ biến nhất với các vấn đề về chuỗi thời gian là LSTM, ta nhận thấy với số ngày nhỏ thì LSTM đạt được độ chính xác tương đương, thậm chí tốt hơn ở một số khí. Tuy nhiên khi số ngày lấy mẫu tăng dần thì điểm mạnh của CNN-LSTM bộc lộ rõ và đạt được độ sai số nhỏ nhất với các khí AQI, PM_{2.5}, SO₂, CO₂, CO là 7%, 5%, 4%, 6%, 7% khi $k=1$ và $days=7$, thấp hơn sai số của thực nghiệm tốt nhất với LSTM các khí AQI, PM_{2.5}, SO₂, CO₂, CO là 9%, 8%, 5%, 8%, 8%.

Thời gian thực hiện

Thời gian thực hiện là khoảng thời gian tính từ khi mô hình nhận được dữ liệu đầu vào đến khi đưa ra được dự đoán của mình. Nói cách khác thời gian thực hiện là khoảng thời gian cần thiết để mô hình thực hiện quá trình xử lý của mình. Một mô hình được coi là tốt khi và chỉ khi nó có thời gian thực hiện và độ chính xác ở mức tốt. Thông thường chúng ta cần phải đánh đổi giữa thời gian thực hiện và độ chính xác của mô hình do mô hình cần nhiều tham số hơn để có thể đưa ra dự đoán chính xác hơn. Một mô hình có thể áp dụng vào thực tiễn chỉ khi nó có thời gian thực hiện đủ nhanh để có thể sử dụng trong cuộc sống hàng ngày.

Chúng tôi đã thực hiện so sánh thời gian chạy của các phương pháp thu được kết quả như sau:

Bảng VI. Thời gian dự đoán 1 điểm dữ liệu

Method		Time
CNN - LSTM	Sử dụng dữ liệu 1 ngày trước	0,047s
	Sử dụng dữ liệu 3 ngày trước	0,052s
	Sử dụng dữ liệu 7 ngày trước	0,067s
Linear Regression		0,00025s
KNN		0,0025s
LSTM		0,057s

Chúng tôi muốn lưu ý rằng thời gian trên là thời gian mà mô hình cần để dự đoán tại 1 điểm duy nhất. Khi số điểm cần dự đoán tăng lên thời gian này cũng tăng lên theo. Tuy nhiên thời gian thực hiện không tăng tuyến tính theo số lượng điểm dữ liệu cần dự đoán. Dưới đây là thời gian cần để dự đoán 6400 điểm dữ liệu tương ứng với 4 khu vực có kích thước 40 x 40m mà chúng tôi sử dụng

trong quá trình huấn luyện mô hình.

Bảng VII. Thời gian dự đoán của 6400 điểm dữ liệu

Method		Time
CNN - LSTM	Sử dụng dữ liệu 1 ngày trước	6,6s
	Sử dụng dữ liệu 3 ngày trước	13,1s
	Sử dụng dữ liệu 7 ngày trước	29,7s
Linear Regression		0,008
KNN		0,43s
LSTM		10,2s

Có thể thấy được rằng, mô hình CNN-LSTM có thời gian thực hiện là cao nhất, điều này khá dễ hiểu do nó cần nhiều tham số hơn để dự đoán cùng với đó độ chính xác của nó cũng là cao nhất. Tuy nhiên, khoảng thời gian trên vẫn có thể phù hợp để sử dụng trong các ứng dụng thực tiễn. Khi so sánh với mô hình LSTM thì mô hình CNN-LSTM với $D = 1$ và $D = 3$ (tương ứng với dữ liệu của 1 và 3 ngày trước đó) tỏ ra vượt trội hơn khi có thời gian chạy tương đương hoặc nhỏ hơn nhưng đem lại độ chính xác cao hơn.

V. KẾT LUẬN

Trong bài báo này, nhóm nghiên cứu đã tiến hành thu thập một bộ dữ liệu của cảm biến đo lường chất lượng không khí trong khuôn viên của Học viện Công nghệ Bưu chính Viễn thông phục vụ cho việc đánh giá chất lượng của mô hình đề xuất và các mô hình khác. Kết quả phân thực nghiệm cho thấy mô hình đề xuất hoạt động tốt với bộ dữ liệu mà nhóm thu thập, chứng tỏ tính khả thi của phương pháp đề xuất khi hoạt động với bộ dữ liệu thực tế. Ngoài ra, nhóm nghiên cứu cũng tiến hành xây dựng một hệ thống hoàn chỉnh từ thiết bị bay đến bộ phận thu nhận dưới mặt đất, phân xử lý dữ liệu bằng mô hình đề xuất và cập nhật thông tin đo lường lên website. Mặc dù đạt được những kết quả hứa hẹn, nghiên cứu này vẫn còn những hạn chế có thể khắc phục, cải thiện trong các nghiên cứu tiếp theo. Nhóm nghiên cứu sẽ tiến hành thử nghiệm thu dữ liệu trên một địa hình rộng hơn, đa dạng hơn, nhằm đánh giá chất lượng không khí đa chiều và khách quan hơn, qua đó phân tích được những sai số của phép đo. Nhóm nghiên cứu cũng hướng đến xây dựng một mô hình học máy đa tác vụ có thể vừa dự đoán chất lượng không khí trong tương lai vừa có khả năng loại bỏ và sửa chữa lỗi của các phép đo. Việc sửa chữa lỗi của phép đo là cần thiết khi tiến hành triển khai ứng dụng trong thực tế bởi vì các phép đo cảm biến giám sát chất lượng không khí luôn tồn tại những ngoại lệ, hoặc không đo lường được dữ liệu. Ngoài ra, nhóm nghiên cứu cũng hướng đến giải quyết bài toán tối ưu quỹ đạo bay của UAV nhằm đo lường hiệu quả và tiết kiệm năng lượng cho thiết bị bay.

LỜI CẢM ƠN

Nghiên cứu này được tài trợ bởi đề tài Bộ TT & TT có mã số **ĐT.24/21**

TÀI LIỆU THAM KHẢO

- [1] 7 million deaths linked to air pollution annually. [Online]. Available: https://www.who.int/phe/eNews_63.pdf
- [2] Moore, Frances. "Climate change and air pollution: exploring the synergies and potential for mitigation in industrializing countries." *Sustainability* 1.1 (2009): 43-54.
- [3] Kalkstein, L.S.; Corrigan, P. A synoptic climatological approach for geographical analysis: Assessment of sulfur dioxide concentrations. *Ann. Assoc. Am. Geogr.* 1986, 76, 381-395.
- [4] Comrie, A.C. A synoptic climatology of rural ozone pollution at three forest sites in Pennsylvania. *Atmos. Environ.* 1994, 28, 1601-1614.
- [5] Eder, B.K.; Davis, J.M.; Bloomfield, P. An automated classification scheme designed to better elucidate the dependence of ozone on meteorology. *J. Appl. Meteorol.* 1994, 33, 1182-1199.xxx
- [6] Zelenka, M.P. An analysis of the meteorological parameters affecting ambient concentrations of acid aerosols in Uniontown, Pennsylvania. *Atmos. Environ.* 1997, 31, 869-878.xxx
- [7] Laakso, L.; Hussein, T.; Aarnio, P.; Komppula, M.; Hiltunen, V.; Viisanen, Y.; Kulmala, M. Diurnal and annual characteristics of particle mass and number concentrations in urban, rural and Arctic environments in Finland. *Atmos. Environ.* 2003, 37, 2629-2641.xxx
- [8] Jacob, D.J.; Winner, D.A. Effect of climate change on air quality. *Atmos. Environ.* 2009, 43, 51-63.x
- [9] Akbari, H. Shade trees reduce building energy use and CO₂ emissions from power plants. *Environ. Pollut.* 2002, 116, S119-S126.x
- [10] DeGaetano, A.T.; Doherty, O.M. Temporal, spatial and meteorological variations in hourly PM_{2.5} concentration extremes in New York City. *Atmos. Environ.* 2004, 38, 1547-1558.x
- [11] Elminir, H.K. Dependence of urban air pollutants on meteorology. *Sci. Total Environ.* 2005, 350, 225-237.x
- [12] Natsagdorj, L.; Jugder, D.; Chung, Y.S. Analysis of dust storms observed in Mongolia during 1937-1999. *Atmos. Environ.* 2003, 37, 1401-1411.x
- [13] Seinfeld, J.H.; Pandis, S.N. *Atmospheric Chemistry and Physics: From Air Pollution to Climate Change*; John Wiley & Sons: Hoboken, NJ, USA, 2016.x
- [14] Twomey, S. The influence of pollution on the shortwave albedo of clouds. *J. Atmos. Sci.* 1977, 34, 1149-1152x
- [15] Zhou, Y.; Chang, F.J.; Chang, L.C.; Kao, I.F.; Wang, Y.S., 2019. Explore a deep learning multi-output neural network for regional multi-step-ahead air quality forecasts. *J. Clean. Prod.* 209, 134e145. <http://www.sciencedirect.com/science/article/pii/S0959652618332694>. <https://doi.org/10.1016/j.jclepro.2018.10.243.x>
- [16] Zhou, Z.; Guo, X.; Wu, H.; Yu, J., 2018. Evaluating air quality in China based on daily data: application of integer data envelopment analysis. *J. Clean. Prod.* 198, 304e311. <http://www.sciencedirect.com/science/article/pii/S0959652618318304>. <https://doi.org/10.1016/j.jclepro.2018.06.180.x>
- [17] D. Byun, K.L. Schere. Review of the governing equations, computational algorithms, and other components of the models-3 community multiscale air quality (cmaq) modeling system *Appl. Mech. Rev.*, 59 (2006), p. 51, 10.1115/1.2128636x
- [18] Close M. Shrivastava, J. Fast, R. Easter, W.I. Gustafson, A. Hodzic. Modeling organic aerosols in a megacity: comparison of simple and complex representations of the volatility basis set approach *Atmos. Chem. Phys.*, 11 (2011), pp. 6639-6662, 10.5194/acpd-10-30205-2010x
- [19] L.T. Wang, Z. Wei, J. Yang, Y. Zhang, F.F. Zhang, J. Su, et al. The 2013 severe haze over southern hebei, China: model evaluation, source apportionment, and policy implications *Atmos. Chem. Phys.*, 14 (2014), pp. 3151-3173x
- [20] Q. Zhang, D. Xue, X. Liu, X. Gong, H. Gao Process analysis of pm_{2.5} pollution events in a coastal city of China using cmaq *J. Environ. Sci.*, 31 (2019), pp. 225-238
- [21] X. Jin, A.M. Fiore, G. Curci, A. Lyapustin, K. Civerolo, M. Ku, et al. Assessing uncertainties of a geophysical approach to estimate surface fine particulate matter distributions from satellite-observed aerosol optical depth *Atmos. Chem. Phys. Discuss.*, 19 (2019)x
- [22] R. Kumar, M.C. Barth, G.G. Pfister, M. Naja, G.P. Brasseur Wrf-chem simulations of a typical pre-monsoon dust storm in northern India: influences on aerosol optical properties and radiation budget *Atmos. Chem. Phys.*, 14 (2014), pp. 2431-2446x
- [23] T. S. Rajput and N. Sharma, "Multivariate regression analysis of air quality index for Hyderabad city: Forecasting model with hourly frequency," *Int. J. Appl. Res.*, vol. 3, no. 8, pp. 443-447, 2017.
- [24] K. P. Singh, S. Gupta, A. Kumar, and S. P. Shukla, "Linear and nonlinear modeling approaches for urban air quality prediction," *Sci. Total Environ.*, vol. 426, pp. 244-255, Jun. 2012.
- [25] S. Dreiseitl and L. Ohno-Machado, "Logistic regression and artificial neural network classification models: A methodology review," *J. Biomed. Inform.*, vol. 35, nos. 5-6, pp. 352-359, 2002.
- [26] A. Azid et al., "Prediction of the level of air pollution using principal component analysis and artificial neural network techniques: A case study in Malaysia," *Water, Air, Soil Pollution*, vol. 225, no. 8, p. 2063, 2014.
- [27] S. De Vito et al., "Dynamic multivariate regression for on-field calibration of high speed air quality chemical multi-sensor systems," in *Proc. AISEM Annu. Conf.*, Feb. 2015, pp. 1-3.
- [28] Z. Kang and Z. Qu, "Application of BP neural network optimized by genetic simulated annealing algorithm to prediction of air quality index in Lanzhou," in *Proc. IEEE Comput. Intell. Appl. (ICCIA)*, Sep. 2017, pp. 155-160.
- [29] C. Paoli, G. Notton, M. Nivet, M. Padovani, and J. Savelli, "A neural network model forecasting for prediction of hourly ozone concentration in Corsica," in *Proc. Environ. Elect. Eng. (EEEIC)*, May 2011, pp. 1-4.
- [30] S. Mahajan, H. M. Liu, T. C. Tsai, and L. J. Chen, "Improving the accuracy and efficiency of PM_{2.5} forecast service using cluster-based hybrid neural network model," *IEEE Access*, vol. 6, pp. 19193-19204, 2018.
- [31] C. Cortes and V. Vapnik, "Support-vector networks," *Mach. Learn.*, vol. 20, no. 3, pp. 273-297, 1995.
- [32] A. S. Sánchez, P. J. G. Nieto, P. R. Fernández, J. J. del Coz Díaz, and F. J. Iglesias-Rodríguez, "Application of an SVM-based regression model to the air quality study at local scale in the Avilés urban area (Spain)," *Math. Comput. Model.*, vol. 54, nos. 5-6, pp. 1453-1466, 2011.
- [33] P. J. G. Nieto, E. García-Gonzalo, F. S. Lasheras, and F. J. de Cos Juez, "Hybrid PSO-SVM-based method for forecasting of the remaining useful life for aircraft engines and evaluation of its reliability," *Rel. Eng. Syst. Saf.*, vol. 138, pp. 219-231, Jun. 2015.
- [34] K. Gu, J. Qiao, and W. Lin, "Recurrent air quality predictor based on meteorology- and pollution-related factors," *IEEE Trans. Ind. Informat.*, vol. 14, no. 9, pp. 3946-3955, Sep. 2018
- [35] X. Li, L. Peng, Y. Hu, J. Shao, and T. Chi, "Deep learning architecture for air quality predictions," *Environ. Sci. Pollut. Res.*, vol. 23, no. 22, pp. 22408-22417, 2016.
- [36] B. T. Ong, K. Sugiura, and K. Zettsu, "Dynamic pre-training of deep recurrent neural networks for predicting environmental monitoring data," in *Proc. IEEE Big Data*, Oct. 2014, pp. 760-765.
- [37] V. Chaudhary, A. Deshbhratar, V. Kumar, and D. Paul. Time Series Based LSTM Model to Predict Air Pollutant's Concentration for Prominent Cities in India. Accessed: Jan. 25, 2019. [Online]. Available: http://philippefourrier-viger.com/utility_mining_workshop_2018/PAPER1.pdf
- [38] E. Pardo and N. Malpica, "Air quality forecasting in Madrid using long short-term memory networks," in *Proc.*

- Int. Work-Conf. Interplay Between Natural Artif. Comput., 2017, pp. 232–239.
- [39] J. Zhao, F. Deng, Y. Cai, and J. Chen, “Long short-term memory-fully connected (LSTM-FC) neural network for PM2.5 concentration prediction,” *Chemosphere*, vol. 220, pp. 486–492, Apr. 2019.
- [40] J. Wang and G. Song, “A deep spatial-temporal ensemble model for air quality prediction,” *Neurocomputing*, vol. 314, pp. 198–206, Nov. 2018.
- [41] Y. Zhou, F.-J. Chang, L.-C. Chang, I.-F. Kao, and Y.-S. Wang, “Explore a deep learning multi-output neural network for regional multi-step ahead air quality forecasts,” *J. Clean Prod.*, vol. 209, pp. 134–145, Feb. 2019.
- [42] M. Kim, Y. Kim, S. Sung, and C. Yoo, “Data-driven prediction model of indoor air quality by the preprocessed recurrent neural networks,” in *Proc. IEEE ICCAS-SICE*, Aug. 2009, pp. 1688–1692.
- [43] İ. Kök, M. U. Şimşek, and S. Özdemir, “A deep learning model for air quality prediction in smart cities,” in *Proc. IEEE Big Data*, Dec. 2017, pp. 1983–1990.
- [44] V. Athira, P. Geetha, R. Vinayakumar, and K. P. Soman, “DeepAirNet: Applying recurrent networks for air quality prediction,” *Procedia Comput. Sci.*, vol. 132, pp. 1394–1403, Dec. 2018.
- [45] B. Wang, Z. Yan, J. Lu, G. Zhang, and T. Li, “Deep multi-task learning for air quality prediction,” in *Proc. Int. Conf. Neural Inf. Process.*, 2018, pp. 93–103.
- [46] X. Sun, W. Xu, and H. Jiang, “Spatial-temporal prediction of air quality based on recurrent neural networks,” in *Proc. 52nd Hawaii Int. Conf. Syst. Sci.*, 2019, pp. 1–10.
- [47] S. Du, T. Li, Y. Yang, and S.-J. Horng. (2018). “Deep air quality forecasting using hybrid deep learning framework.” [Online]. Available: <https://arxiv.org/abs/1812.04783>
- [48] F. Feng, J. Wu, W. Sun, Y. Wu, H. Li, and X. Chen, “Haze forecasting via deep LSTM,” in *Proc. Asia-Pacific Web (APWeb) Web-Age Inf. Manage. (WAIM) Joint Int. Conf. Web Big Data*, 2018, pp. 349–356.
- [49] C.-J. Huang and P.-H. Kuo, “A deep CNN-LSTM model for particulate matter (PM2.5) forecasting in smart cities,” *Sensors*, vol. 18, no. 7, p. 2220, 2018.
- [50] [50] Y. LeCun and Y. Bengio, “Convolutional networks for images, speech, and time series,” in *The Handbook of Brain Theory and Neural Networks*, vol. 3361, no. 10. Cambridge, MA, USA: MIT Press, 1995.
- [51] P.-W. Soh, J.-W. Chang, and J.-W. Huang, “Adaptive deep learning-based air quality prediction model using the most relevant spatial-temporal relations,” *IEEE Access*, vol. 6, pp. 38186–38199, 2018.
- [52] Z. Pan, Y. Liang, J. Zhang, X. Yi, Y. Yu, and Y. Zheng. (2018). “HyperSTNet: Hypernetworks for Spatio-temporal forecasting.” [Online]. Available: <https://arxiv.org/abs/1809.10889>

AIR QUALITY INDEX PREDICTION USING CONVOLUTIONAL NEURAL NETWORK AND LONG SHORT-TERM MEMORY

Abstract: Air quality monitoring is not only a challenging but also a practical research topic in the field of machine learning and data analytics. Air quality directly affects human health and their daily activities. Therefore, the air quality index has always received much attention from people as well as the local government. Currently, ground-based air quality monitoring stations are commonly established to provide air quality measurement at monitoring areas. Unmanned Aerial Vehicles (UAVs) are also gradually being used for surveillance applications using cameras. However, using UAV in monitoring and predicting air quality is still a new field that is receiving much attention from large research groups around the world. To solve the problem of predicting air quality based on sensor values measured from unmanned aerial vehicles, we propose a

model combining a unidirectional convolutional neural network and long-short memory network (CNN-LSTM). With the results obtained from testing with the data set that we have collected, our proposed model has achieved promising results on the testing dataset collected. Our model is capable of being deployed in real applications, adding a useful source of quality monitoring in conjunction with existing ground-based stations.

Keywords: Convolutional neural networks, air quality index, long short-term memory



Nguyễn Việt Hưng. Tốt nghiệp thạc sĩ năm 2009 tại ĐH Bách Khoa Grenoble và bảo vệ luận án Tiến sĩ năm 2013 tại đại học Rennes 1, CH Pháp. Hiện công tác tại Học viện Công nghệ Bưu chính Viễn thông. Lĩnh vực nghiên cứu: Hệ thống thông tin thế hệ mới, trí tuệ nhân tạo, học máy.
Email: nvhung_vt1@ptit.edu.vn



Vũ Hoài Nam. Tốt nghiệp đại học chuyên ngành điện tử viễn thông, Đại học Bách Khoa Hà Nội năm 2013. Tốt nghiệp Thạc sĩ chuyên ngành Kỹ Sư Máy Tính, Đại học Quốc gia Chonnam năm 2015. Hiện nay đang là nghiên cứu sinh chuyên ngành Khoa Học Máy Tính, Học Viện Công Nghệ Bưu Chính Viễn Thông. Lĩnh vực nghiên cứu bao gồm xử lý ảnh, thị giác máy tính, thuật toán và trí tuệ nhân tạo.
Email: namvh@ptit.edu.vn



Vũ Đức Anh. Sinh viên ngành Công nghệ thông tin, Học viện Công nghệ Bưu chính Viễn thông, Hà Nội. Lĩnh vực nghiên cứu bao gồm xử lý ảnh, thị giác máy tính, học máy, dịch máy và trí tuệ nhân tạo.
Email: anhvda



Trần Quang Hiệp. Sinh viên ngành Công nghệ thông tin, Học viện Công nghệ Bưu chính Viễn thông, Hà Nội. Lĩnh vực nghiên cứu bao gồm xử lý ngôn ngữ tự nhiên, thị giác máy tính, học máy và trí tuệ nhân tạo.
Email: hieptran.jobs@gmail.com



Lê Thành Long. Hiện là sinh viên năm 4 chuyên ngành hệ thống thông tin tại Học viện Công nghệ Bưu chính Viễn thông (PTIT). Lĩnh vực nghiên cứu chính bao gồm: xử lý ảnh, thị giác máy tính, học máy và trí tuệ nhân tạo.
Email: lethanhlong582000@gmail.com